

MEMORIA del PLAN DE INVESTIGACIÓN

DOCTORANDO/A: Julio César Ibarra Fiallo

DNI/PASAPORTE: 0602069346

TUTOR/DIRECTOR: Juan Alfonso Lara Torralbo

PROGRAMA DE DOCTORADO: Computación avanzada, energía y plasmas.

LÍNEA DE INVESTIGACIÓN:

DEPARTAMENTO:

TÍTULO DEL PLAN DE INVESTIGACIÓN (ESPAÑOL) (Obligatorio): Superresolución de series temporales por caracterización de patrones integrando matrices transformadoras y conjuntos rugosos.

TÍTULO DEL PLAN DE INVESTIGACIÓN (INGLÉS) (Obligatorio): Super resolution of time series by characterization of patterns integrating transformers and rough sets.

(Extensión máxima 3 páginas)

1. Describir brevemente las razones por las cuales se considera pertinente plantear esta investigación y, en su caso, la hipótesis de partida en la que se sustentan los objetivos del proyecto de tesis (máximo 20 líneas)

Encontrar patrones en series temporales para el pronóstico de comportamientos o la comprensión de eventos es fundamental dentro de muchos ámbitos, análisis de señales, detección de anomalías, pronóstico de tiempo, pronósticos económicos, etc. Buscar patrones que permitan la reconstrucción más fina de la información, lo que implica la disminución del factor de escala uniforme y la obtención de información entre datos proporcionados abre las puertas para la extensión del concepto de contexto.

Si se piensa en una matriz transformadora como el medio de consecución de información entre dos contextos diferentes, mediante técnicas de aprendizaje profundo se puede obtener patrones de un primer contexto de resolución baja (escala gruesa), temporalmente hablando se podría pensar primero en horas, que se transforman a un segundo contexto, el de superresolución (escala fina), digamos minutos. Esta reconstrucción de información se ha logrado ya antes, por ejemplo en la reconstrucción temporal y geométrica de imágenes mediante el uso de interpoladores y de redes generativas, en este ámbito ya se nota la necesidad de la contextualización de la información obtenida para guiar la reconstrucción de información deseada.

Finalmente, la selección de patrones relevantes que alimenten la codificación de elementos vectoriales de información queda delegada a las capacidades selectivas de los conjuntos rugosos, conjuntos de valores capaces de mantener la calidad de la detección de un patrón, pero con menos descriptores que los originalmente tomados.

En resumen, la hipótesis que se maneja es que se pueden usar las matrices transformadores para cambiar de un contexto de una serie temporal de baja resolución, a un contexto de alta resolución de una serie temporal, determinando patrones adecuados, obtenidos a partir de técnicas de cálculo de conjuntos rugosos.

2. Indicar los antecedentes y resultados previos que avalan la validez de la hipótesis de partida

El análisis de series temporales busca estudiar los patrones y las tendencias en los datos que se recopilan a lo largo del tiempo. Una idea importante en este campo es el desarrollo de modelos basados en aprendizaje profundo para la previsión de series temporales. Estos modelos, como LSTM (Long Short Term Memory) y GRU (Gated Recurrent Unit), han mostrado resultados prometedores en la predicción precisa de valores futuros de datos de series temporales (S. Hochreiter, 1997) (N. Elsayed, 2019). Existe

interés en el uso de modelos de aprendizaje profundo (Deep Learning) para la detección de eventos en datos de series temporales (Yuxiu Hua, 2019).

La superresolución es el proceso de aumentar la resolución de una imagen o video más allá de su resolución original. Si se piensa en una serie temporal de datos como una señal cualquiera, las técnicas de superresolución se pueden transferir. El uso de redes antagónicas generativas (GAN) para superresolución, ha demostrado producir resultados de alta calidad y en el campo de las imágenes, resultados visualmente agradables (Yu Chen, 2018) (Andrew Brock, 2018). En este campo la definición de contexto es fundamental, las señales de intensidad de luz que evolucionan hacia una señal de alta calidad, solo lo pueden hacer por una buena contextualización.

Las matrices transformadoras (transformers) son un tipo de arquitectura de red neuronal que se ha desarrollado como sustituto de las redes neuronales recurrentes (RNN) en el procesamiento del lenguaje natural (NLP) y otras tareas de modelado de sucesiones, superando las limitaciones de paralelización, problemas del gradiente y captura de dependencias a largo plazo (Ashish Vaswani, 2017). El potencial para generar cambios de contexto de las matrices transformadoras se puede utilizar en favor de la generación de nueva información para lograr alta resolución desde un contexto de baja resolución. En el caso de series temporales se debe trabajar en la definición de contexto de partida, baja resolución y el de destino alta resolución. En ambos casos, codificación y decodificación adecuadas de la información a espacios vectoriales es un campo abierto de estudio.

Los conjuntos rugosos fueron desarrollados por Zdzislaw Pawlak en la década de los 80's para tratar con datos imprecisos e inciertos. En el corazón de la teoría de conjuntos rugosos se encuentra el concepto de conjunto rugoso, que se define como un par (U, R) , donde U es un universo de objetos y R es una relación binaria en U . La relación R representa la relación de indiscernibilidad, que captura la idea de que dos objetos en U son indistinguibles con respecto a un cierto conjunto de atributos, en otras palabras, R agrupa objetos que son similares en términos de sus atributos. Con base en esta relación de indiscernibilidad, se pueden realizar diversas tareas en el análisis de datos y la toma de decisiones, como la reducción de atributos, la determinación de reglas y la clasificación (Pawlak, 1982). Por ejemplo, la reducción de atributos implica encontrar un subconjunto mínimo de atributos que puedan representar un conjunto de objetos en U sin pérdida de información. Esta teoría es paralela a la teoría de Testores Típicos, cuyos algoritmos, si bien computacionalmente intensivos, son usados para la obtención de subconjuntos robustos en la determinación de patrones de clasificación (M. S. Lazo-Cortés, 2015).

3. Enumerar brevemente y describir con claridad, precisión y de manera realista (es decir, acorde con la duración prevista de la tesis) los **objetivos concretos** que se persiguen

Objetivo general.

Generar un modelo de superresolución basado en matrices de transformación y conjuntos rugosos que permita aumentar la resolución de series temporales con las mayores precisión y eficiencia, a partir de la detección de patrones codificables y decodificables para cambios de contexto.

Objetivos específicos.

1. Estudiar, experimentar con arquitecturas de matrices de transformación para aplicarlas a dos contextos, el primero de baja resolución (datos originales) y el segundo de superresolución (datos generados).
2. Estudiar la aplicabilidad de la teoría de conjuntos rugosos en la determinación del contexto inicial de baja resolución, tomando atributos que permitan la determinación de reglas de codificación.
3. Realizar experimentos y pruebas basadas en el deterioro de series temporales de alta resolución que permitan validar la reconstrucción de datos.
4. Analizar la aplicabilidad del modelo en la detección de eventos a partir de datos temporales.

4. Especificar brevemente el diseño experimental (en su caso) o el trabajo empírico a realizar en términos de metodología y procedimientos objetivables (máximo 500 palabras), o indicar **3 publicaciones** de los últimos 6 años del director/es en las que se utilice dicha metodología.

1. Diseño del modelo: Diseñar un modelo para generar superresolución de series temporales, siguiendo la lógica:

1. Deterioro de una serie temporal.

2. Aplicación de técnicas de regularización de datos, de ser necesario
 3. Cálculo de conjuntos rugosos que optimicen la codificación de datos a un espacio vectorial de R^n . Determinación del contexto de partida
 4. Entrenamiento del modelo basado en transformers para el cambio de contexto.
 5. Decodificación de resultados en R^m con m mucho mayor que n con la serie en superresolución. Determinación del contexto de llegada.
2. Modulación de hiperparámetros: Tamaño mínimo de conjuntos rugosos, dimensionalidad de los contextos de partida y de llegada. Determinación de capas y neuronas por capa del modelo neuronal. Este procedimiento estará basado en parámetros sugeridos en arquitecturas ya usadas en la bibliografía y en experimentación propia.
 3. Evaluación del modelo: Evaluar el rendimiento del modelo, comparando la serie temporal recuperada con la señal original (sin deterioro).
 4. Análisis de resultado: Analizar los resultados obtenidos, reportar los patrones de la señal original que pudieron generar información importante en la recuperación de datos, también informar de cuáles son los patrones con menos posibilidad de reconstrucción.

5. Referencias bibliográficas (máximo 10, de gran relevancia para el trabajo que se emprende) que han debido ser mencionadas de manera precisa en los apartados 2 y 4

1. Yuxiu Hua, Z. Z. (2019). Deep Learning with Long Short-Term Memory for Time Series Prediction. *IEEE Communications Magazine*, 114-119.
2. S. Hochreiter, J. S. (1997). Long Short-Term Memory. *Neural Computation*, 1735-1780.
3. N. Elsayed, A. S. (2019). N. Elsayed, A. S. Maida and M. Bayoumi. 2019 *International Conference on Internet of Things (iThings) and IEEE Green Computing and Communications (GreenCom) and IEEE Cyber, Physical and Social Computing (CPSCom) and IEEE Smart Data (SmartData)*, Atlanta, GA, USA (pp. 1207-1210). Atlanta: IEEE.
4. Yu Chen, Y. T. (2018). End-to-end learning face super-resolution with facial priors. *IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2493-2501). IEEE.
5. Andrew Brock, J. D. (2018). Large Scale GAN Training for High Fidelity Natural Image Synthesis. *CoRR*, <http://arxiv.org/abs/1809.11096>.
6. Ashish Vaswani, N. S. (2017). Attention Is All You Need. *CoRR*, <http://arxiv.org/abs/1706.03762>
7. Pawlak, Z. (1982). Rough sets. *International journal of computer & information sciences* 11 , 341-356.
8. M. S. Lazo-Cortés, J. A.-O.-T.-D. (2015). Computing constructs by using typical testor algorithms. *Mexican Conference on Pattern Recognition*, (pp. 44-53). Springer.

EL DOCTORANDO/A

EL TUTOR/DIRECTOR

Fdo.:

Fdo.:

Se informa que el proyecto de tesis puede ser desarrollado en el periodo señalado por la normativa de Doctorado de la UCO, y que cuenta con los medios y financiación necesarios.